

Pembahasan Latihan Soal UAS Machine Learning

Exercise Machine Learning - 2

Lecturer: Afiahayati, S.Kom., M.Cs., Ph.D.

Format bahan belajar: soal + jawaban ringkas, 2 kolom per halaman.

K-Nearest Neighbor (3-NN)

Soal. Lihat Tabel 1. Tentukan kelas (Y) untuk data uji menggunakan metode 3-nearest neighbor dengan jarak Euclidean.

	Training Data						Testing Data	
X_1	2	1	2	3	1	3	2	1
X_2	2	2	3	3	0	2	1	1
Y	-1	1	-1	1	1	-1	?	?

Jawaban singkat. Rumus jarak Euclidean:

$$d(p, q) = \sqrt{(x_{1p} - x_{1q})^2 + (x_{2p} - x_{2q})^2}.$$

Misalkan data latih:

ID	(X_1, X_2)	Y
A	$(2, 2)$	-1
B	$(1, 2)$	1
C	$(2, 3)$	-1
D	$(3, 3)$	1
E	$(1, 0)$	1
F	$(3, 2)$	-1

Data uji 1: $T_1 = (2, 1)$.

Hitung jarak T_1 ke semua data latih:

$$\begin{aligned} d(T_1, A) &= \sqrt{(2-2)^2 + (1-2)^2} = 1, \\ d(T_1, B) &= \sqrt{(2-1)^2 + (1-2)^2} = \sqrt{2}, \\ d(T_1, C) &= \sqrt{(2-2)^2 + (1-3)^2} = 2, \\ d(T_1, D) &= \sqrt{(2-3)^2 + (1-3)^2} = \sqrt{5}, \\ d(T_1, E) &= \sqrt{(2-1)^2 + (1-0)^2} = \sqrt{2}, \\ d(T_1, F) &= \sqrt{(2-3)^2 + (1-2)^2} = \sqrt{2}. \end{aligned}$$

ID	A	B	C	D	E	F
$d(T_1, \cdot)$	1	$\sqrt{2}$	2	$\sqrt{5}$	$\sqrt{2}$	$\sqrt{2}$
Y	-1	1	-1	1	1	-1

Urutan jarak terkecil: $A(1)$, lalu seri $B, E, F(\sqrt{2})$, kemudian $C(2)$ dan $D(\sqrt{5})$. Dengan aturan tie-break urutan data, tiga tetangga terdekat adalah $A(-1), B(1), E(1)$. Voting: dua kelas 1 dan satu kelas -1, sehingga mayoritas = 1.

$$Y(T_1) = 1.$$

Catatan: Pada T_1 ada jarak seri di $\sqrt{2}$. Jika dosen menentukan aturan tie-break lain, tetangga ketiga bisa berubah. Di sini dipakai aturan urutan data karena soal tidak memberi aturan khusus.

Data uji 2: $T_2 = (1, 1)$.

Hitung jarak T_2 ke semua data latih:

$$\begin{aligned} d(T_2, A) &= \sqrt{(1-2)^2 + (1-2)^2} = \sqrt{2}, \\ d(T_2, B) &= \sqrt{(1-1)^2 + (1-2)^2} = 1, \\ d(T_2, C) &= \sqrt{(1-2)^2 + (1-3)^2} = \sqrt{5}, \\ d(T_2, D) &= \sqrt{(1-3)^2 + (1-3)^2} = \sqrt{8}, \\ d(T_2, E) &= \sqrt{(1-1)^2 + (1-0)^2} = 1, \\ d(T_2, F) &= \sqrt{(1-3)^2 + (1-2)^2} = \sqrt{5}. \end{aligned}$$

ID	A	B	C	D	E	F
$d(T_2, \cdot)$	$\sqrt{2}$	1	$\sqrt{5}$	$\sqrt{8}$	1	$\sqrt{5}$
Y	-1	1	-1	1	1	-1

Urutan jarak terkecil: $B(1), E(1), A(\sqrt{2})$, lalu $C, F(\sqrt{5})$ dan $D(\sqrt{8})$. Tiga tetangga terdekat: $B(1), E(1), A(-1)$. Voting: dua kelas 1 dan satu kelas -1, sehingga mayoritas = 1.

$$Y(T_2) = 1.$$

Hasil akhir testing data:

$$(2, 1) \rightarrow 1, \quad (1, 1) \rightarrow 1$$

Support Vector Machine

Soal. Jelaskan untuk data seperti apa Support Vector Machine cocok digunakan.

Jawaban singkat. SVM cocok untuk:

- Data klasifikasi numerik yang dapat dipisahkan oleh hyperplane, baik linear maupun non-linear.
- Data berdimensi tinggi, misalnya teks, fitur vektor, atau citra yang sudah diekstraksi fiturnya.
- Dataset kecil sampai menengah, terutama saat ingin margin pemisah yang besar.
- Data non-linear jika memakai kernel, misalnya RBF atau polynomial.

Sebelum memakai SVM, fitur sebaiknya dinormalisasi atau distandarisasi agar skala fitur tidak mendominasi jarak/margin.

Naive Bayes: CategoricalNB

Soal. Perhatikan kode pada Gambar 1. Jelaskan cara kerja metode machine learning pada kode tersebut.

Deskripsi Gambar 1. Gambar berisi kode Python yang mengimpor modul `naive_bayes`, membuat model `CategoricalNB()`, melatih model dengan `fit(X_train, y_train)`, lalu memprediksi data uji dengan `predict(X_test)`.

```
from sklearn import naive_bayes
nb = naive_bayes.CategoricalNB()
nb.fit(X_train, y_train)
y_pred = nb.predict(X_test)
```

Jawaban singkat. Kode tersebut menggunakan **Naive Bayes untuk fitur kategorikal**. Cara kerjanya:

1. `CategoricalNB()` membuat model Naive Bayes untuk data kategori/diskrit.

2. `fit(X_train, y_train)` menghitung prior kelas $P(Y)$ dan peluang fitur kategori terhadap kelas $P(X_i | Y)$.
3. Model mengasumsikan setiap fitur saling independen bersyarat terhadap kelas.
4. `predict(X_test)` memilih kelas dengan posterior terbesar:

$$\hat{y} = \arg \max_c P(c) \prod_{i=1}^d P(x_i | c).$$

Hasil akhirnya disimpan pada `y_pred`.

Ensemble Learning

Bagging, Boosting, dan Stacking

Soal. Jelaskan algoritma bagging, boosting, dan stacking serta perbedaannya.

Jawaban singkat. Bagging atau bootstrap aggregating:

- Membuat beberapa dataset baru dari data latih dengan sampling bootstrap.
- Melatih beberapa model secara paralel.
- Prediksi akhir diperoleh dari voting mayoritas atau rata-rata.
- Tujuan utama: menurunkan variance dan mengurangi overfitting.

Contoh: Random Forest.

Boosting:

- Melatih model lemah secara berurutan.
- Model berikutnya lebih fokus pada data yang salah diprediksi oleh model sebelumnya.
- Prediksi akhir berupa voting berbobot.
- Tujuan utama: menurunkan bias dan meningkatkan akurasi.

Contoh: AdaBoost, Gradient Boosting.

Stacking:

- Melatih beberapa model dasar yang bisa berbeda jenis.
- Output model dasar dijadikan input untuk meta-model.
- Meta-model belajar menggabungkan prediksi model dasar.

Perbedaan inti:

Aspek	Bagging	Boosting	Stacking
Pola latih Data	Paralel Bootstrap	Berurutan Berbobot, fokus error	Dua level Prediksi base model
Gabungan	Voting/rata-rata	Voting berbobot	Meta-model
Fokus	Kurangi variance	Kurangi bias	Kombinasi model

Parameter AdaBoost

Soal. Perhatikan Gambar 2. Jelaskan arti `base_classifier`, `n_estimators`, dan `learning_rate`.

Deskripsi Gambar 2. Gambar berisi potongan kode pembuatan `AdaBoostClassifier` dengan parameter `base_classifier`, `n_estimators=50`, `learning_rate=1.0`, dan `random_state=42`; lalu model dilatih menggunakan `fit(X_train, y_train)`.

```
adaboost_classifier = AdaBoostClassifier(
    base_classifier,
    n_estimators=50,
    learning_rate=1.0,
    random_state=42
)
adaboost_classifier.fit(X_train, y_train)
```

Jawaban singkat.

- `base_classifier`: model dasar/weak learner yang dipakai AdaBoost, misalnya decision stump.
- `n_estimators=50`: jumlah weak learner yang akan dibuat dalam proses boosting.
- `learning_rate=1.0`: mengatur besar kontribusi setiap weak learner terhadap prediksi akhir. Nilai kecil membuat pembelajaran lebih hati-hati.
- `random_state=42`: membuat hasil random dapat direproduksi.

Implementasi Bagging Manual

Soal. Perhatikan Tabel 2. Implementasikan algoritma Bagging untuk data dengan hanya 3 bootstrapping/single model. Tulis prediksi akhir dan hitung akurasi.

x	2.4	3.1	3.7	4.4	5.2	5.8
y	1	1	1	-1	-1	-1

Jawaban singkat. Catatan: Soal tidak menentukan sampel bootstrap acak dan jenis base learner. Untuk latihan manual, digunakan asumsi base learner berupa decision stump/threshold pada fitur x . Karena data terpisah sempurna antara $x = 3.7$ dan $x = 4.4$, batas yang wajar adalah $x = 4.05$.

Aturan model tunggal:

$$h(x) = \begin{cases} 1, & x < 4.05, \\ -1, & x \geq 4.05. \end{cases}$$

Contoh 3 bootstrap dan model yang terbentuk:

Model	Indeks bootstrap	Aturan
h_1	1,2,3,4,5,5	$x < 4.05 \Rightarrow 1$
h_2	1,1,2,3,4,6	$x < 4.05 \Rightarrow 1$
h_3	2,3,3,4,5,6	$x < 4.05 \Rightarrow 1$

Prediksi masing-masing model pada data sumber:

x	2.4	3.1	3.7	4.4	5.2	5.8
y asli	1	1	1	-1	-1	-1
h_1	1	1	1	-1	-1	-1
h_2	1	1	1	-1	-1	-1
h_3	1	1	1	-1	-1	-1
Voting	1	1	1	-1	-1	-1

Prediksi akhir Bagging:

$$\hat{y} = [1, 1, 1, -1, -1, -1].$$

Akurasi:

$$\text{Accuracy} = \frac{\text{jumlah benar}}{\text{jumlah data}} = \frac{6}{6} = 1 = \boxed{100\%}.$$

Ringkasan Jawaban Cepat

- 3-NN testing: $(2, 1) \rightarrow 1$ dan $(1, 1) \rightarrow 1$ dengan tie-break urutan data.
- SVM cocok untuk data numerik, berdimensi tinggi, dan memiliki margin pemisah yang jelas; bisa non-linear dengan kernel.
- **CategoricalNB**: menghitung prior dan conditional probability kategori, lalu memilih kelas dengan posterior terbesar.
- Bagging: paralel + bootstrap + voting. Boosting: sequential + fokus error + voting berbobot. Stacking: base model + meta-model.
- AdaBoost: `base_classifier = weak learner`, `n_estimators = jumlah learner`, `learning_rate = bobot kontribusi learner`.
- Bagging manual pada Tabel 2: prediksi $[1, 1, 1, -1, -1, -1]$, akurasi 100% berdasarkan asumsi stump $x < 4.05$.