

Pembahasan Ringkas Latihan Soal UAS Machine Learning

Bahan Belajar - Format 2 Kolom

Semester II 2024/2025

1. Data Preparation dan Evaluation

1a. Train-Test Split

Soal: Dari kode pada Gambar 1, jika total data adalah 500 dan `train_size = 0.7`, tuliskan output program.

Deskripsi Gambar 1: potongan kode Python memakai `train_test_split(X,y, train_size=0.7)` lalu mencetak jumlah data latih dan data uji.

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, train_size
=0.7)
print("Banyak data latih setelah dilakukan Train-Test Split: ", len(
X_train))
print("Banyak data uji setelah dilakukan Train-Test Split: ", len(
X_test))
```

Jawab:

$$|X_{train}| = 0.7 \times 500 = 350, \quad |X_{test}| = 500 - 350 = 150.$$

Output:

```
Banyak data latih setelah dilakukan Train-Test Split: 350
Banyak data uji setelah dilakukan Train-Test Split: 150
```

1b. K-Fold Cross Validation

Soal: Jelaskan *k-fold cross validation*. Kapan digunakan?

Jawab: *k-fold cross validation* membagi data menjadi *k* bagian/fold berukuran kurang lebih sama. Alurnya:

1. Fold ke-1 dipakai sebagai data validasi, fold lain untuk training.
2. Ulangi sampai setiap fold pernah menjadi data validasi satu kali.
3. Hitung skor tiap percobaan, lalu ambil rata-ratanya.

Dipakai ketika data terbatas, ingin evaluasi model lebih stabil, dan ingin membandingkan model/hyperparameter tanpa terlalu bergantung pada satu pembagian train-test.

1c. Confusion Matrix dan Metrik

Soal: Dari Tabel 1 berikut, buat confusion matrix lalu hitung accuracy, sensitivity/recall, precision, dan F1-measure. Kelas positif adalah YES.

No	Target	Prediksi
1	No	No
2	No	YES
3	YES	YES
4	YES	No
5	YES	YES
6	No	No
7	No	No
8	YES	No
9	YES	YES
10	YES	No
11	YES	No
12	YES	YES

Jawab: Ambil kelas positif = YES. Dari tabel:

$$TP = \{3, 5, 9, 12\} = 4, \quad FN = \{4, 8, 10, 11\} = 4,$$

$$FP = \{2\} = 1, \quad TN = \{1, 6, 7\} = 3.$$

	Pred. YES	Pred. No
Aktual YES	TP = 4	FN = 4
Aktual No	FP = 1	TN = 3

$$\text{Accuracy} = \frac{TP + TN}{12} = \frac{7}{12} = 58.33\%.$$

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{4}{8} = 50\%.$$

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{4}{5} = 80\%.$$

$$F1 = \frac{2PR}{P + R} = \frac{2(0.8)(0.5)}{0.8 + 0.5} = 61.54\%.$$

Jadi model benar pada 7 dari 12 data, tetapi recall kelas YES hanya 50% karena 4 dari 8 data YES diprediksi No.

2. K-Nearest Neighbor (K-NN)

2a. K-NN Cocok untuk Dataset Besar karena Prediksi Cepat

Soal: Tentukan benar/salah dan berikan alasan.

Jawab: Salah. K-NN adalah *lazy learner*; saat prediksi, model menghitung jarak data baru ke banyak/semua data latih. Jika dataset besar, prediksi cenderung lambat dan butuh memori besar. K-NN lebih sederhana saat training karena hampir hanya menyimpan data, tetapi beban komputasi besar muncul saat prediksi.

2b. K-NN Harus Memakai Euclidean Distance

Soal: Tentukan benar/salah dan berikan alasan.

Jawab: Salah. Euclidean distance hanya salah satu pilihan. K-NN bisa memakai Manhattan, Minkowski, cosine similarity, Hamming distance, atau metrik lain sesuai tipe data. Contoh: Hamming cocok untuk fitur biner/kategorikal sederhana, sedangkan cosine sering dipakai untuk vektor teks.

3. Naive Bayes: Play Tennis

3a. Probability Table dan Prediksi D15

Soal: Diberikan data Play Tennis. Buat tabel probabilitas, lalu tentukan apakah pada D15 disarankan bermain tenis untuk kondisi: Outlook = Rain, Temperature = Mild, Humidity = Normal, Wind = Weak. Soal menyebut D15 dan D16, tetapi atribut cuaca yang tertulis hanya D15.

Day	Outlook	Temp.	Humid.	Wind	Play
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Jawab: Jumlah kelas: Play = YES ada 9, Play = No ada 5.

Probabilitas	Play=Yes	Play=No
$P(C)$	9/14	5/14
Outlook=Sunny	2/9	3/5
Outlook=Overcast	4/9	0/5
Outlook=Rain	3/9	2/5
Temp=Hot	2/9	2/5
Temp=Mild	4/9	2/5
Temp=Cool	3/9	1/5
Humidity=High	3/9	4/5
Humidity=Normal	6/9	1/5
Wind=Weak	6/9	2/5
Wind=Strong	3/9	3/5

Untuk D15 = Rain, Mild, Normal, Weak:

$$S_{Yes} = \frac{9}{14} \cdot \frac{3}{9} \cdot \frac{4}{9} \cdot \frac{6}{9} \cdot \frac{6}{9} = 0.04233.$$

$$S_{No} = \frac{5}{14} \cdot \frac{2}{5} \cdot \frac{2}{5} \cdot \frac{1}{5} \cdot \frac{2}{5} = 0.00457.$$

Normalisasi posterior:

$$P(Yes | x) = \frac{0.04233}{0.04233 + 0.00457} = 0.9026,$$

$$P(No | x) = \frac{0.00457}{0.04233 + 0.00457} = 0.0974.$$

Karena $S_{Yes} > S_{No}$, maka prediksi D15 adalah **Play Tennis = YES**. Soal menyebut D15 dan D16, tetapi PDF hanya memberi atribut cuaca untuk D15; karena itu yang dapat dihitung dari data soal adalah D15.

3b. Naive Bayes untuk Data Numerik

Soal: Naive Bayes awalnya untuk data kategorikal, tetapi bisa untuk data numerik. Jelaskan caranya.

Jawab: Untuk fitur numerik, gunakan **Gaussian Naive Bayes**. Untuk setiap fitur dan setiap kelas, hitung mean μ_C dan varians σ_C^2 dari data latih. Likelihood nilai numerik dihitung dengan distribusi normal:

$$P(x | C) = \frac{1}{\sqrt{2\pi\sigma_C^2}} \exp\left(-\frac{(x - \mu_C)^2}{2\sigma_C^2}\right).$$

Untuk banyak fitur:

$$Score(C) = P(C) \prod_i P(x_i | C).$$

Nilai likelihood tiap fitur dikalikan dengan prior kelas, lalu pilih kelas dengan score/posterior terbesar. Alternatif lain untuk data numerik adalah diskretisasi/binning, tetapi Gaussian NB adalah jawaban umum.

4. Ensemble Learning

4a. Bagging, Boosting, dan Stacking

Soal: Jelaskan algoritma bagging, boosting, stacking, dan perbedaannya.

Jawab: Bagging: membuat beberapa data bootstrap dari data latih, melatih beberapa model secara paralel, lalu menggabungkan hasil dengan voting/average. Tujuan utama: mengurangi variance. Contoh: Random Forest.

Boosting: melatih model lemah secara berurutan. Model berikutnya memberi perhatian lebih pada data yang salah diprediksi model sebelumnya. Tujuan utama: mengurangi bias dan menaikkan akurasi. Contoh: AdaBoost, Gradient Boosting.

Stacking: melatih beberapa model dasar yang bisa berbeda jenis, lalu prediksi model dasar dijadikan input untuk model akhir/meta-learner.

Aspek	Bagging	Boosting	Stacking
Pola Data	Paralel Bootstrap	Berurutan Fokus error/bobot	Dua level Output base model
Gabung	Voting/rata-rata	Voting berbobot	Meta-model
Fokus	Variance	Bias	Kombinasi model

4b. Parameter AdaBoost

Soal: Dari Gambar 2, jelaskan arti `base_classifier`, `n_estimators`, dan `learning_rate`.

Deskripsi Gambar 2: potongan kode membuat `AdaBoostClassifier(base_classifier, n_estimators=50, learning_rate=1.0, random_state=42)` lalu melakukan `fit(X_train, y_train)`.

Jawab:

- **base_classifier:** model dasar/weak learner yang dipakai AdaBoost, misalnya decision stump.
- **n_estimators=50:** jumlah weak learner yang dilatih secara berurutan.
- **learning_rate=1.0:** besar kontribusi tiap weak learner; semakin kecil biasanya lebih stabil tetapi butuh lebih banyak estimator.
- **random_state=42:** seed agar proses acak dapat direproduksi.

4c. Bagging dengan 3 Model

Soal: Implementasikan bagging pada data berikut dengan 3 bootstrap/single model. Tulis prediksi akhir dan akurasi.

x	2.4	3.1	3.7	4.4	5.2	5.8	6.4
y	1	1	1	-1	-1	-1	-1

Jawab: Karena sampel bootstrap acak dan jenis base learner tidak dicantumkan pada soal, dipakai asumsi umum untuk latihan manual: base learner berupa *decision stump* pada fitur x . Data terpisah jelas pada batas tengah antara 3.7 dan 4.4:

$$\theta = \frac{3.7 + 4.4}{2} = 4.05.$$

Aturan model tunggal:

$$h(x) = \begin{cases} 1, & x < 4.05, \\ -1, & x \geq 4.05. \end{cases}$$

Contoh tiga bootstrap yang tetap menghasilkan stump sama:

Model	Indeks bootstrap	Aturan
h_1	1,2,3,4,5,6,7	$x < 4.05 \Rightarrow 1$
h_2	1,1,2,3,4,6,7	$x < 4.05 \Rightarrow 1$
h_3	2,3,3,4,5,6,7	$x < 4.05 \Rightarrow 1$

x	2.4	3.1	3.7	4.4	5.2	5.8	6.4
y asli	1	1	1	-1	-1	-1	-1
h_1	1	1	1	-1	-1	-1	-1
h_2	1	1	1	-1	-1	-1	-1
h_3	1	1	1	-1	-1	-1	-1
Voting	1	1	1	-1	-1	-1	-1

Voting mayoritas memberi:

$$\hat{y} = [1, 1, 1, -1, -1, -1, -1].$$

Semua prediksi sama dengan label asli, sehingga:

$$\text{Accuracy} = \frac{7}{7} \times 100\% = 100\%.$$

Catatan: jika bootstrap acak ditentukan berbeda oleh soal, prediksi model tunggal dapat berubah, tetapi prediksi akhir bagging tetap diambil dari voting mayoritas 3 model.

5. Clustering

5a. Clustering vs Classification

Soal: Jelaskan perbedaan clustering dan classification.

Jawab: Clustering adalah unsupervised learning: data tidak memiliki label, lalu sistem mencari kelompok berdasarkan kemiripan. Contoh: membagi pelanggan menjadi beberapa segmen tanpa label awal.

Classification adalah supervised learning: data latih memiliki label, lalu model memprediksi label untuk data baru. Contoh: memprediksi email spam/tidak spam dari data email yang sudah diberi label.

5b. Elbow Method untuk K-Means

Soal: Jelaskan cara menentukan nilai k optimal pada k-means. Berdasarkan Gambar 3, tentukan nilai k optimal.

Deskripsi Gambar 3: grafik elbow method menampilkan Sum of Squared Distances terhadap jumlah cluster k . Penurunan sangat tajam terjadi dari $k = 2$ ke $k = 3$, kemudian kurva mulai melandai.

Jawab: Cara menentukan k dengan elbow method:

1. Jalankan k-means untuk beberapa nilai k .
2. Hitung SSE/Sum of Squared Distances tiap k .
3. Plot k terhadap SSE.
4. Pilih titik siku, yaitu titik ketika penambahan k mulai memberi penurunan SSE yang tidak terlalu besar.

Dari grafik, penurunan terbesar terjadi dari $k = 2$ ke $k = 3$, lalu setelah itu kurva mulai lebih landai. Titik siku paling jelas berada di:

$$\boxed{k = 3}$$

Jadi jumlah cluster optimal adalah sekitar **3 cluster**.